

Прогнозирование цен на недвижимость

Введение

Среди предложенных на выбор проектов я решил выбрать проект по прогнозированию цен на недвижимость на примере датасета Boston Housing. Этот проект направлен на использование линейной регрессии для прогнозирования цен на жильё на основе данных о его характеристиках, таких как площадь, количество комнат, возраст дома и другие параметры.

Основные шаги:

- Загрузить набор данных о ценах на жильё.
- Разделить данные на обучающую и тестовую выборки.
- Построить модель линейной регрессии.
- Оценить точность модели, используя метрики, такие как среднеквадратичная ошибка (MSE).

Реализация

Итак, начнём с подключения всех необходимых библиотек и загрузки датасета Boston Housing? содержащий характеристики домов (площадь, количество комнат, налог, криминогенность района и т. д.), а также целевую переменную `medv` — цену жилья.:

```
using CSV
using DataFrames
using GLM
using Plots
using Random
using Statistics

url = "https://raw.githubusercontent.com/selva86/datasets/master/BostonHousing.csv"
data = CSV.read(download(url), DataFrame)
```

Подключенные библиотеки:

- CSV — библиотека для чтения CSV-файлов
- DataFrames — библиотека для удобной работы с таблицами
- GLM — библиотека для построения моделей обобщённых линейных моделей, в т. ч. линейная регрессия
- Plots — библиотека для визуализации данных
- Random — библиотека для работы со случайными числами
- Statistics — библиотека с базовыми статистическими функциями

Далее посмотрим на размер данных из нашего датасета, организуем просмотр первых строчек из файла, соберём основную статистику по данным (Рис. 1) и визуализируем целевую переменную (Рис. 2):

```
println("\nРазмерность данных: ", size(data))

println("Первые 10 строк данных:")
display(first(data, 10))

println("\nСтатистика данных:")
display(describe(data))

histogram(data.medv, xlabel="Цена жилья (medv)", ylabel="Частота",
title="Распределение цен")
```

Размерность данных: (506, 14)														
Первые 10 строк данных:														
10x14 DataFrame														
Row	crim	zn	indus	chas	nox	rm	age	dis	rad	tax	ptratio	b	lstat	medv
	Float64	Float64	Float64	Int64	Float64	Float64	Float64	Float64	Int64	Int64	Float64	Float64	Float64	Float64
1	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.09	1	296	15.3	396.9	4.98	24.0
2	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242	17.8	396.9	9.14	21.6
3	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242	17.8	392.83	4.03	34.7
4	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222	18.7	394.63	2.94	33.4
5	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222	18.7	396.9	5.33	36.2
6	0.02985	0.0	2.18	0	0.458	6.43	58.7	6.0622	3	222	18.7	394.12	5.21	28.7
7	0.08829	12.5	7.87	0	0.524	6.012	66.6	5.5685	5	311	15.2	395.6	12.43	22.9
8	0.14455	12.5	7.87	0	0.524	6.172	96.1	5.9505	5	311	15.2	396.9	19.15	27.1
9	0.21124	12.5	7.87	0	0.524	5.631	100.0	6.0821	5	311	15.2	386.63	29.93	16.5
10	0.17004	12.5	7.87	0	0.524	6.004	85.9	6.5921	5	311	15.2	386.71	17.1	18.9
Статистика данных:														
14x7 DataFrame														
Row	variable	mean	min	median	max	rmissing	eltype							
	Symbol	Float64	Real	Float64	Real	Int64	DataType							
1	crim	3.61352	0.00632	0.25651	88.9762	0	Float64							
2	zn	11.3636	0.0	0.0	100.0	0	Float64							
3	indus	11.1368	0.46	9.69	27.74	0	Float64							
4	chas	0.06917	0	0.0	1	0	Int64							
5	nox	0.554695	0.385	0.538	0.871	0	Float64							
6	rm	6.28463	3.561	6.2085	8.78	0	Float64							
7	age	68.5749	2.9	77.5	100.0	0	Float64							
8	dis	3.79504	1.1296	3.20745	12.1265	0	Float64							
9	rad	9.54941	1	5.0	24	0	Int64							
10	tax	408.237	187	330.0	711	0	Int64							
11	ptratio	18.4555	12.6	19.05	22.0	0	Float64							
12	b	356.674	0.32	391.44	396.9	0	Float64							
13	lstat	12.6531	1.73	11.36	37.97	0	Float64							
14	medv	22.5328	5.0	21.2	50.0	0	Float64							

Рисунок 1 – Анализ данных




Рисунок 2 – Гистограмма распределения цен

- Первая часть выводит количество строк и столбцов в исходном файле
- Вторая часть выводит первые 10 строк
- Третья часть выводит основную статистику по данным в файле (минимальное, среднее и максимальное значения, дисперсия и т. д.)
- Четвёртая часть визуализирует распределение цен в виде гистограммы

Следующие шагом станет разделение данных на обучающую и тестовую выборки:

```
Random.seed!(777)
n = nrow(data)
shuffledIndexes = shuffle(1:n)
trainSize = Int(round(0.8 * n))
trainIndexes = shuffledIndexes[1:trainSize]
testIndexes = shuffledIndexes[trainSize+1:end]
trainDataFrame = data[trainIndexes, :]
testDataFrame = data[testIndexes, :]
```

Разбираемся:

- Первая строчка – это, так сказать, фиксация случайности. То есть, при повторном запуске числа, сгенерированные сидом 777, не изменятся
- Вторая строчка – это присвоение переменной значения, равного количеству строк в исходном датасете
- Третья строчка – простое перемешивание индексов
- Четвёртая строчка – это нахождение количества индексов, которое составит 80% от всей выборки, и сохранение этого значения в переменную
- Пятая строчка – создание массива из индексов, количество которых составляет 80% от всей выборки, для тренировки модели
- Шестая строчка - создание массива из индексов, количество которых составляет 20% от всей выборки, для тестирования модели
- Седьмая строчка – создания выборки строк по индексам для тренировки
- Восьмая строчка – создания выборки строк по индексам для тренировки

Далее следует построение модели линейной регрессии и вывод коэффициентов этой модели. Для этого была задана зависимость цены от всех признаков, а по ней уже построена модель линейной регрессии. После этого, путём перебора признаков и их коэффициентов, были выведены коэффициенты модели:

```
formula = @formula(medv ~ crim + zn + indus + chas + nox + rm + age + dis + rad +  
tax + ptratio + b + lstat)  
model = lm(formula, trainDataFrame)  
  
println("\nКоэффициенты модели:")  
ct = coefTable(model)  
for (name, coef) in zip(coefnames(model), coef(model))  
    println(rpad(name, 12), " = ", round(coef, digits=4))  
end
```

Следующий шаг: прогнозирование и оценка качества модели для этого введём 2 переменных для реальной цены и предсказанной моделью. Далее с помощью этих величин будут рассчитаны метрики MSE, RMSE и т. д.:

```
y_true = testDataFrame.medv
y_pred = predict(model, testDataFrame)

mse = mean((y_true .- y_pred).^2)
rmse = sqrt(mse)
mae = mean(abs.(y_true .- y_pred))
r2 = 1 - sum((y_true .- y_pred).^2) / sum((y_true .- mean(y_true)).^2)

println("\nОценка модели на тестовой выборке:")
println("Среднеквадратичная ошибка (MSE): ", round(mse, digits=2))
println("Среднеквадратичная ошибка (RMSE): ", round(rmse, digits=2))
println("Средняя абсолютная ошибка (MAE): ", round(mae, digits=2))
println("Коэффициент детерминации (R²): ", round(r2, digits=2))
```

Первые две строчки – это реальная и предсказанная моделью цены соответственно. Далее следуют расчёты среднеквадратической ошибки, корня из неё же, средней абсолютной ошибки и коэффициента детерминации. Результаты этого и прошлого этапов представлены на рисунке 3:

```
Коэффициенты модели:
(Intercept) = 38.241
crim        = -0.0696
zn          = 0.058
indus       = 0.0197
chas        = 2.8206
nox         = -19.5257
crim        = -0.0696
zn          = 0.058
indus       = 0.0197
chas        = 2.8206
nox         = -19.5257
indus       = 0.0197
chas        = 2.8206
nox         = -19.5257
nox         = -19.5257
rm          = 3.4392
rm          = 3.4392
age         = 0.0065
dis         = -1.6408
rad         = 0.3034
tax         = -0.0121
ptratio     = -0.8651
ptratio     = -0.8651
b           = 0.0108
b           = 0.0108
lstat       = -0.5674
lstat       = -0.5674

Оценка модели на тестовой выборке:
Среднеквадратичная ошибка (MSE): 20.24
Среднеквадратичная ошибка (RMSE): 4.5
Средняя абсолютная ошибка (MAE): 3.56
Коэффициент детерминации (R²): 0.74
```

Рисунок 3 – Выведенные коэффициенты и рассчитанные метрики

Последний этап – визуализация результатов. Каждая точка будет отображать пара значений: реальную и предсказанную моделью цены. Красной линией будет соответствовать идеальное совпадение реальной и предсказанной моделью цен, поэтому чем ближе к линии, тем лучше. Результата представлен на рисунке 4.

```
scatter(y_true, y_pred, xlabel="Реальные значения", ylabel="Предсказанные значения",  
        title="Предсказанные vs Реальные значения", legend=false)  
plot!(LinRange(minimum(y_true), maximum(y_true), 10),  
       LinRange(minimum(y_true), maximum(y_true), 10),  
       linewidth=3, linecolor=:red)
```




Рисунок 4 – Предсказанные vs Реальные значения

Вывод

В ходе реализации проекта по прогнозированию цен на недвижимость на примере датасета Boston Housing были продемонстрированы все этапы работы: анализ данных, построение модели, оценка качества модели с помощью метрик, итоговая визуализация результатов.